PROYEK 1 • GENERATIVE AI / NLP

Salamanca

# IndoMiniBERT: Generasi Judul Berita Bahasa Indonesia

Implementasi Arsitektur Transformer Encoder dari Nol untuk Kontrol Clickbait vs Non-Clickbait


Muhammad Hanif Pearlyaradja

103012340237

Muhammad Zayyad Azizan

103012340211

Calvin Nathaniel

103012340285

Nesha Rizqika Dwinity

103012340359

Almer Akbar Alqifari

103012340484

LATAR BELAKANG & MOTIVASI

# Tantangan Generasi pada Transformer Encoder

## Polarisasi Gaya Berita

Media digital Indonesia terpolarisasi antara judul faktual berstruktur lugas dan judul sensasional pemikat rasa ingin tahu pembaca.

**Fokus: Mengendalikan sentimen gaya tanpa mengorbankan kualitas sintaksis.**

## Dua Masalah Inti Proyek

Membangun model BERT dari nol tanpa library transformers, lalu merekayasa representasi dwiarah untuk teks generatif terarah.

**Solusi: Integrasi metode non-autoregressive Mask-Predict.**

TAHAP 1 • DATA ENGINEERING

# Dataset CLICK-ID & Tokenizer WordPiece

### Korpus Berita

15.000 judul teranotasi biner beserta 46.000 artikel utuh.

### Anti Data-Leakage

Pembersihan ketat memastikan split uji murni terisolasi.

### Token Gaya Khusus

Penambahan token [CB] dan [NCB] dalam 16.000 kosakata.

TAHAP 2 • SPESIFIKASI TEKNIS

# Arsitektur Mini-BERT Murni PyTorch

## Konfigurasi Lapisan Model

Encoder Layers
**4 Lapisan**

Hidden Dimension
**256 Dimensi**

Feed-Forward
**1024 Dimensi**

Attention Heads
**4 Kepala (64/d)**

Multi-Head Attention dihitung manual melalui proyeksi matriks Q, K, V terukur.

## Dual Head & Efisiensi

### Weight Tying Efisien

Bobot matriks embedding input diikat ke proyeksi output MLM.

### BertForMaskedLM

Rekonstruksi token rumpang untuk proses generasi.

### BertForSequenceClassification

Klasifikasi biner gaya berita melalui representasi [CLS].

TAHAP 3 & 4 • PELATIHAN MODEL

# Pretraining MLM & Conditioning Gaya

STEP 03

## Dynamic Masking

15% masking acak per sampel (80% [MASK], 10% substitusi acak, 10% identik).

Optimasi menggunakan AdamW & Linear Warmup.

STEP 04

## Style-Conditioning

Penyisipan token gaya permanen [CB] atau [NCB] di posisi awal setelah [CLS].

Token kontrol gaya dilarang di-mask selama training.

ABLATION

## Studi Ablasi Klasifikasi

Pretrained encoder mengungguli inisialisasi bobot acak secara signifikan.

Membuktikan transfer semantik hasil pretraining berhasil.

TAHAP 5 • MEKANISME GENERASI

# Alur Kerja Algoritma Mask-Predict

01

## Inisialisasi

Menyusun template rumpang terkontrol token gaya target.

`[CLS][GAYA][MASK]...`

02

## First-Pass

Prediksi berurutan memanfaatkan konteks kalimat sisi kiri.

`Sequential Pass`

03

## Refinement

Me-mask ulang token berprobabilitas rendah via atensi dwiarah.

`Iterative Polish`

04

## Sintaksis

Penegakan struktur SPOK dan pencegahan preposisi gantung.

`Linguistic Guard`

FITUR PENGGUNA

# Tiga Mode Fleksibilitas Generasi

### Generasi Bebas

Model mandiri merancang kerangka kalimat sesuai gaya terpilih.

### Mode Template

Pengguna mengontrol kalimat dengan parameter --prompt rumpang.

### Kata Kunci

Menyusun berita seputar entitas spesifik via --keywords.

HASIL GENERASI

# Komparasi Clickbait vs Non-Clickbait

| Gaya Target | Contoh Output Model | Karakteristik Linguistik |
|---|---|---|
| **Non-Clickbait** | `presiden jokowi resmikan tol di riau` | Faktual, lugas, berpola SPOK jelas. |
| **Non-Clickbait** | `pemprov dki jakarta tertibkan pelaku di rumah` | Fokus aksi kelembagaan dan regulasi. |
| **Clickbait** | `ini alasan pria mundur dari partai` | Memicu curiosity gap pembaca. |
| **Clickbait** | `begini reaksi pemain saat tahu kabar duka` | Eksploitasi emosi dengan diksi hiperbolis. |

KINERJA & PENGUJIAN

# Metrik Evaluasi Kualitas Teks

### Kebaruan (Novelty)

**100%**

Generasi murni sintesis baru tanpa menghafal dataset latihan.

### Diversitas Kata (Distinct-2)

**0.885**

Variasi n-gram tinggi tanpa gejala pengulangan repetitif.

### Kelancaran (Perplexity Median)

**192.5**

Turun drastis dari baseline bobot acak (~51 juta).

ENGINEERING HIGHLIGHTS

# Tantangan Teknis & Rekayasa Solusi

## Fragmentasi Subword

Imbuhan terpecah (misal resmi ##kan) mengacaukan filter POS kata kerja.

**Solusi: Backward subword merger merekonstruksi kata dasar sebelum inferensi.**

## Bias Entitas Dominan

Korpus September 2019 bias isu tokoh nasional di sembarang posisi predikat.

**Solusi: Syntactic POS constraints membatasi konteks lokasi setelah preposisi "di".**

PENUTUP & RENCANA

# Kesimpulan & Pengembangan Lanjutan

## Capaian Utama

Berhasil merekayasa arsitektur BERT manual menjadi model generatif terkontrol gaya menggunakan algoritma Mask-Predict.

**Tata bahasa sintaksis terbukti mencegah anomali teks generatif.**

## Rencana Pengembangan

Eksplorasi pretraining skala besar korpus Wikipedia Indonesia dan integrasi feedback reinforcement learning classifier.

**Penyempurnaan feedback loop classifier secara real-time.**

SESI TANYA JAWAB

# Terima Kasih

Silakan mengajukan pertanyaan seputar implementasi teknis IndoMiniBERT dan algoritma Mask-Predict.

 github.com/salamanca/indominibert

 Demo CLI & Notebook Tersedia